

Exploração em Fine-Tuning através de GraphRAG



Um estudo de caso prático de definições, exploração e consolidação de conhecimento sobre métodos de Fine-Tuning através de ferramentas de GraphRAG.

Deivdson Pereira
Paulo Vinicius
Tiago Fernandes

PPGEEC2327 - TÓPICOS ESPECIAIS EM PROCESSAMENTO
INTELIGENTE DA INFORMAÇÃO

PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA
ELÉTRICA E DE COMPUTAÇÃO

Problema vs. Tema

PROBLEMA

Uma **visão geral de técnicas** e requisitos necessários para implementação de métodos de treinamento de **dados específicos** em LLM. Qual método utilizar para uma dada natureza de dados ou tarefa?

TEMA

Fine-Tuning e seus diversos métodos e variações.

Metodologia

1. Coletar um **acervo de materiais** relacionados ao **tema de *Fine-Tuning* (FT)** e detalhamento e aplicações de seus métodos;
 2. Injetar acervo em ferramenta de **GraphRAG (EdgeQuake)** para **visão geral** do tema e facilidade de **parametrização de métodos** e seus **relacionamentos**;
 3. Utilizar **GraphRAG + LLM** para esclarecimentos e geração de **informações agregadas** sobre o tema.
- *Avaliar aplicabilidade de métodos de FT em natureza de dados e tarefa específicas.*

Considerações gerais

- Acervo com 12 documentos (artigos e sites);
- 3k+ entidades;
- 4k+ relacionamentos;
- Principais entidades extraída: LoRA, QLoRA, PEFT etc;



Considerações gerais

Tabela Comparativa de Métodos de Ajuste (Fine-Tuning) e Destilação em Modelos de Linguagem

Característica	Fine-tuning (FT) Completo	PEFT (Parameter-Efficient Fine-Tuning) Geral	LoRA (Low-Rank Adaptation)	IA3 (Infused Adapter)	Adapters (Camadas de Adaptadores)	Prompt Tuning	Destilação de Conhecimento	Outros PEFTs Mencionados
Descrição/Objetivo	Método convencional para adaptar modelos pré-treinados, treinando-os em um novo conjunto de dados específico, atualizando todos os parâmetros.	Adaptação de modelos pré-treinados modificando apenas uma pequena fração de seus parâmetros.	Método de "delta tuning" e ajuste eficiente de parâmetros, utilizando uma estrutura de "gargalo" (bottleneck) similar à dos adaptadores.	Técnica de ajuste eficiente de parâmetros (PEFT) que infunde adaptadores para inibir e amplificar ativações internas.	Técnica que "congela" os parâmetros existentes de um modelo e injeta novos, permitindo o ajuste independente para um domínio-alvo. Insere pequenos módulos treináveis em cada camada.	Alternativa ao fine-tuning que evita alterações na arquitetura do modelo. É um algoritmo de "delta tuning".	Técnica onde um modelo estudante menor aprende de um modelo professor maior, para comprimir conhecimento sem perder a essência da inteligência.	QLoRA: Quantização para reduzir pegada de memória. AlphaTuning: Método de ajuste que mostra melhor desempenho e se adapta a diferentes tamanhos de modelo. DiReFT/LoReFT: Mais precisos, mas podem envolver computação extra por mudanças arquitetônicas. SMART: Um único modelo que atinge resultados SOTA.
Eficiência/Custo Computacional	Alto custo computacional, pois todos os parâmetros do modelo devem ser atualizados. Requer grande espaço de armazenamento (e.g., GPT-2 L: 3096MB).	Reduz os custos computacionais ajustando apenas um subconjunto de parâmetros. Permite encaixar modelos maiores na memória da GPU.	Projetado para reduzir custos computacionais e requerimentos de armazenamento.	Permite ajustar e encaixar modelos maiores (aprox. 68 parâmetros) na memória da GPU com número reduzido de parâmetros.	Similar ao Prompt Tuning em flexibilidade.	Mais eficiente computacionalmente e custo-eficaz do que a destilação de conhecimento.	Reduz demandas computacionais, mas é menos eficiente e custo-eficaz que o Prompt Tuning.	QLoRA: Reduz ainda mais a pegada de memória. DiReFT/LoReFT: Podem envolver computação extra devido a mudanças arquitetônicas.
Desempenho	Alta performance. Serve como forte linha de base (e.g., RoBERTa-Large com perda de entropia	Desempenho superior em um conjunto diverso de LLMs. Muito competitivo mesmo utilizando	No RoBERTa, se iguala ou supera o fine-tuning completo. No GPT-2 M, superou o FT com 55.8 BLEU. Melhorou o desempenho em modelos CodeGen e DeepSeekCoder. LoRA no CodeGen superou o fine-tuning completo. Geralmente obteve melhores resultados que IA3 (em 21 de 24 casos), embora Li et	A análise do Knowledge Graph indica que IA3 pode ter um desempenho melhor que LoRA com menos parâmetros treináveis. No entanto, experimentos mostram que LoRA superou	Geralmente supera o Prompt Tuning em tarefas complexas e	Geralmente superado por métodos baseados em adaptadores.	(O contexto não especifica o desempenho comparativo direto da	QLoRA: Tende a ter pior desempenho devido à perda de precisão. AlphaTuning: Resultados comparáveis ao LoRA. DiReFT: Atinge 95.6% em LLaMA-2 8B. SMART: Alcança

- PEFT, LoRA, QLoRA e IA³ maior aderência para treinamento em geração de código;
- Há métodos destinados a: segurança/privacidade, limitações de hardware, etc.