

Exploração do Fine-Tuning através de GraphRAG



Um estudo de caso prático da exploração de conceitos e consolidação de conhecimento sobre métodos de Fine-Tuning assistido por ferramentas de GraphRAG.

Deivdson Pereira
Paulo Vinicius
Tiago Fernandes

PPGEEC2327 - TÓPICOS ESPECIAIS EM PROCESSAMENTO
INTELIGENTE DA INFORMAÇÃO

PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA
ELÉTRICA E DE COMPUTAÇÃO

Introdução

Tema

Fine-tuning e seus diversos métodos e variações.

Problemática

Obter uma **visão geral de técnicas** e requisitos necessários para implementação dos diferentes métodos de treinamento eficiente em LLM.

Justificativa

Assistir a compreensão das técnicas e **agilizar** a tomada de decisões de implementação, considerando especialmente um usuário com pouca experiência.

Metodologia

Tendo em vista alcançar a compreensão das técnicas de forma assistida por LLM, planejamos os seguintes passos:

1. Coletar um **acervo de materiais** relacionados ao **tema de *Fine-Tuning* (FT)** e detalhamento e aplicações de seus métodos;
2. Injetar acervo nas ferramentas de **GraphRAG**.
3. Utilizar **GraphRAG + LLM** para esclarecimentos e geração de **informações agregadas** sobre o tema, avaliando vantagens, desvantagens, aplicabilidade e relacionamentos das técnicas de fine-tuning;
4. Comparação da qualidade de resposta das diferentes ferramentas.

Base de Conhecimento

A base de conhecimento utilizada para ancorar as ferramentas consistiu em um acervo com 12 documentos (textos acadêmicos e artigos da internet). Isso gerou um Knowledge Graph com:

- 3k+ entidades;
- 4k+ relacionamentos;
- Principais entidades extraídas foram: LoRA, QLoRA, PEFT etc.



Primeiro Teste: Sumarização das Técnicas de FT

Prompt

“Resuma os métodos de fine-tuning e a relação entre comparativa entre eles. Sumarize isso em formato de tabela comparativa.”

Resultado Esperado

- Tabela estruturada;
- Descrição de cada método;
- Explicação das diferenças entre cada método;
- Citar a aplicabilidade de cada método;
- Fundamentar as afirmações com base nas referências fornecidas.

Primeiro Teste: EdgeQuake

Tabela Comparativa de Métodos de Ajuste (Fine-Tuning) e Destilação em Modelos de Linguagem

Característica	Fine-tuning (FT) Completo	PEFT (Parameter-Efficient Fine-Tuning) Geral	LoRA (Low-Rank Adaptation)	IA3 (Infused Adapter)	Adapters (Camadas de Adaptadores)	Prompt Tuning	Destilação de Conhecimento	Outros PEFTs Mencionados
Descrição/Objetivo	Método convencional para adaptar modelos pré-treinados, treinando-os em um novo conjunto de dados específico, atualizando todos os parâmetros.	Adaptação de modelos pré-treinados modificando apenas uma pequena fração de seus parâmetros.	Método de "delta tuning" e ajuste eficiente de parâmetros, utilizando uma estrutura de "gargalo" (bottleneck) similar à dos adaptadores.	Técnica de ajuste eficiente de parâmetros (PEFT) que infunde adaptadores para inibir e amplificar ativações internas.	Técnica que "congela" os parâmetros existentes de um modelo e injeta novos, permitindo o ajuste independente para um domínio-alvo. Insere pequenos módulos treináveis em cada camada.	Alternativa ao fine-tuning que evita alterações na arquitetura do modelo. É um algoritmo de "delta tuning".	Técnica onde um modelo estudante menor aprende de um modelo professor maior, para comprimir conhecimento sem perder a essência da inteligência.	QLoRA: Quantização para reduzir pegada de memória. AlphaTuning: Método de ajuste que mostra melhor desempenho e se adapta a diferentes tamanhos de modelo. DiReFT/LoReFT: Mais precisos, mas podem envolver computação extra por mudanças arquitetônicas. SMART: Um único modelo que atinge resultados SOTA.
Eficiência/Custo Computacional	Alto custo computacional, pois todos os parâmetros do modelo devem ser atualizados. Requer grande espaço de armazenamento (e.g., GPT-2 L: 3096MB).	Reduz os custos computacionais ajustando apenas um subconjunto de parâmetros. Permite encaixar modelos maiores na memória da GPU.	Projetado para reduzir custos computacionais e requerimentos de armazenamento.	Permite ajustar e encaixar modelos maiores (aprox. 68 parâmetros) na memória da GPU com número reduzido de parâmetros.	Similar ao Prompt Tuning em flexibilidade.	Mais eficiente computacionalmente e custo-eficaz do que a destilação de conhecimento.	Reduz demandas computacionais, mas é menos eficiente e custo-eficaz que o Prompt Tuning.	QLoRA: Reduz ainda mais a pegada de memória. DiReFT/LoReFT: Podem envolver computação extra devido a mudanças arquitetônicas.
Desempenho	Alta performance. Serve como forte linha de base (e.g., RoBERTa-Large com perda de entropia	Desempenho superior em um conjunto diverso de LLMs. Muito competitivo mesmo utilizando	No RoBERTa, se iguala ou supera o fine-tuning completo. No GPT-2 M, superou o FT com 55.8 BLEU. Melhorou o desempenho em modelos CodeGen e DeepSeekCoder. LoRA no CodeGen superou o fine-tuning completo. Geralmente obteve melhores resultados que IA3 (em 21 de 24 casos), embora Li et	A análise do Knowledge Graph indica que IA3 pode ter um desempenho melhor que LoRA com menos parâmetros treináveis. No entanto, experimentos mostram que LoRA superou	Geralmente supera o Prompt Tuning em tarefas complexas e	Geralmente superado por métodos baseados em adaptadores.	(O contexto não especifica o desempenho comparativo direto da	QLoRA: Tende a ter pior desempenho devido à perda de precisão. AlphaTuning: Resultados comparáveis ao LoRA. DiReFT: Atinge 95.6% em LLaMA-2 8B. SMART: Alcança

- Métodos PEFT: LoRA, QLoRA e IA³; Maior aderência para treinamento em geração de código;
- Há métodos destinados a: segurança/privacidade, limitações de hardware, etc.

Primeiro Teste: Graphify

TIPO DE TAREFA/DADO	LORA	QLORA	ADAPTER	PROMPT TUNING	FT COMPLETO
Assistente de Código	● Ideal	● Ideal	● Viável	● Limitado	● Ideal
Tradução Multilíngue	● Ideal	● Viável	● Ideal	● Viável	● Ideal
Sumarização	● Ideal	● Ideal	● Viável	● Viável	● Ideal
Análise de Intenção	● Ideal	● Ideal	● Ideal	● Ideal	● Viável
Análise de Sentimento	● Ideal	● Ideal	● Ideal	● Ideal	● Viável
Extração de Entidades	● Ideal	● Ideal	● Ideal	● Viável	● Viável
Resposta a Perguntas	● Ideal	● Ideal	● Viável	● Viável	● Ideal
Geração Criativa	● Viável	● Viável	● Viável	● Ideal	● Ideal
Suporte ao Cliente	● Viável	● Ideal	● Ideal	● Ideal	● Limitado
Domínios Especializados	● Viável	● Limitado	● Viável	● Limitado	● Ideal
Dados Limitados	● Ideal	● Ideal	● Ideal	● Ideal	● Limitado
Edge/Mobile (Low Latency)	● Viável	● Ideal	● Viável	● Ideal	● Limitado

Recomendação Final: QLoRA (18x menos memória, 99% qualidade retida, LLaMA-65B viável em GPU 48GB, Versatilidade para qualquer cenário)

Primeiro Teste: NotebookLM

Tabela Comparativa de Métodos de Fine-Tuning

Método	Custos Computacionais / Memória	Latência na Inferência / Mudança de Arquitetura	Parâmetros Treináveis (%)	Características e Relação Comparativa
Full Fine-Tuning (FT)	Muito Altos [32, 33]	Nenhuma / Nenhuma	100% [34]	O padrão-ouro em eficácia, mas com alto risco de <i>overfitting</i> (esquecimento catastrófico) e custo impraticável para modelos na escala de bilhões de parâmetros [4, 8].
Adapters	Baixos [11, 12]	Aumentada (devido ao processamento sequencial) / Adição de módulos [12, 14]	~0,5% a 8% [13]	Ótimo para aprendizagem multi-tarefa, mas, em comparação ao LoRA, perde vantagem na velocidade de inferência por aumentar o fluxo de dados (caminho mais longo) [14, 35].
Prompt Tuning	Muito Baixos [36]	Nenhuma / Modifica a entrada (anexa tokens) [16, 37]	Altíssima eficiência (<0,1%) [38]	Em comparação a outros PEFTs, é o mais fácil de implementar , porém converge lentamente e tem pior desempenho em modelos menores em relação ao LoRA ou Adapters [17].
LoRA	Baixos [22, 39]	Nenhuma (os pesos são mesclados) / Nenhuma mudança fixa [23, 27]	~0,1% a 2% [38, 40]	Muito superior ao Prompt Tuning em estabilidade. Oferece desempenho comparável ao Full FT , mas evita latência na inferência e permite trocar adaptadores para tarefas diferentes facilmente [22, 41].
QLoRA	Mínimos [24, 25]	Nenhuma / Usa pesos quantizados em 4-bit [24, 25]	Similar ao LoRA	Evolução do LoRA , focada na democratização: permite treinar LLMs gigantes em hardware modesto (ex: GPUs comerciais), ao custo de leve perda de informação [24, 25].

Primeiro Teste: Resultados

EdgeQuake

- Trouxe porcentagem de parâmetros treináveis;
- Citou modelos que utilizaram cada método.
- Trouxe referências aglomeradas ao final da resposta.

Graphify

- Criou analogias e pseudocódigo para facilitar a compreensão;
- Trouxe recomendações de qual técnica utilizar dadas as suas prioridades (ex. tempo de inferência, RAM disponível...);
- Trouxe referências aos nós do grafo aglomeradas ao final da resposta.

NotebookLM

- Trouxe porcentagem de parâmetros treináveis;
- Citou impactos que cada técnica poderia apresentar no tempo de inferência;
- Trouxe referências para cada afirmação feita.

Segundo Teste: Construção de Timeline das técnicas

Prompt

“Explique detalhadamente todas as técnicas de fine-tuning abordadas pelas fontes. Apresente-as em ordem cronológica de surgimento e evidencie para cada uma:

- As técnicas e conceitos que as inspiraram;
- Vantagens e desvantagens em relação às suas antecessoras;
- Pontos importantes para a utilização delas na prática.”

Resultado Esperado

- Atendimento aos 3 requisitos;
- Fundamentar as afirmações com base nas referências fornecidas.

Segundo Teste: Resultados

EdgeQuake

- Trouxe as técnicas na sequência correta de publicação;
- **Não** citou os anos de publicação de cada técnica;
- Trouxe referências aglomeradas ao final da resposta.

Graphify

- Trouxe as técnicas na sequência correta de publicação;
- Citou os anos de publicação de cada técnica;
- Criou analogias e pseudocódigo para facilitar a compreensão;
- Citou fontes de forma esporádica;
- Deu uma recomendação final.

NotebookLM

- Trouxe as técnicas na sequência correta de publicação;
- Citou os anos de publicação de cada técnica;
- Satisfez os 3 requisitos exigidos no prompt.
- Trouxe referências para cada afirmação feita.

Conclusão

Nosso grupo avaliou as três ferramentas como sendo, no geral, satisfatórias à problemática proposta. Apesar disso, entendemos que o EdgeQuake e o Graphify ainda não tem um nível de maturidade comparável ao do NotebookLM, que traz muitas funcionalidades indisponíveis nas outras ferramentas.

EdgeQuake

Pontos Fortes:

- Flexibilidade para integração com outras soluções;
- Facilidade de instalação.

Pontos Fracos:

- Não trouxe referências ao longo do texto.

Graphify

Pontos Fortes:

- Integração com assistentes de IA por meio da IDE, sem necessidade da criação de tokens;

Pontos Fracos:

- Não trouxe referências ao longo do texto.

NotebookLM

Pontos Fortes:

- Trouxe referências para cada afirmação feita.

Pontos Fracos:

- Não deve ser utilizado com informações privadas ou sigilosas.